Selenium 与 PhantomJS

动态 HTML 介绍

JavaScript

JavaScript 是网络上最常用也是支持者最多的客户端脚本语言。它可以收集 用户的跟踪数据,不需要重载页面直接提交表单，在页面嵌入多媒体文件，甚至运行网页游戏。

jQuery

jQuery 是一个十分常见的库,70% 最流行的网站(约 200 万)和约 30% 的其他网站(约 2 亿)都在使用。一个网站使用 jQuery 的特征,就是源代码里包含了 jQuery 入口,比如:

如果你在一个网站上看到了 jQuery，那么采集这个网站数据的时候要格外小心。jQuery 可以动态地创建 HTML 内容,只有在 JavaScript 代码执行之后才会显示。如果你用传统的方法采集页面内容,就只能获得 JavaScript 代码执行之前页面上的内容。

Ajax

我们与网站服务器通信的唯一方式，就是发出 HTTP 请求获取新页面。如果提交表单之后，或从服务器获取信息之后，网站的页面不需要重新刷新，那么你访问的网站就在用 Ajax 技术。

Ajax 其实并不是一门语言,而是用来完成网络任务(可以认为 它与网络数据采集差不多)的一系列技术。Ajax 全称是 Asynchronous JavaScript and XML(异步 JavaScript 和

XML)，网站不需要使用单独的页面请求就可以和网络服务器进行交互 (收发信息)。

DHTML

Ajax 一样，动态 HTML(Dynamic HTML, DHTML)也是一系列用于解决网络问题的 技术集合。DHTML 是用客户端语言改变页面的 HTML 元素(HTML、CSS，或者二者皆 被改变)。比如页面上的按钮只有当用户移动鼠标之后才出现,背景色可能每次点击都会改变，或者用一个 Ajax 请求触发页面加载一段新内容，网页是否属于 DHTML，关键要看有没有用 JavaScript 控制 HTML 和 CSS 元素。

解决办法

用 Python 解决这个问题只有两种途径:

- 直接从 JavaScript 代码里采集内容（费时费力）
- 用 Python 的 第三方库运行 JavaScript，直接采集你在浏览器里看到的页面。

动态页面爬取环境配置

Selenium 简介

Selenium 是一个 Web 的自动化测试工具，类型像我们玩游戏用的按键精灵，它支持所有主流的浏览器（包括 PhantomJS 这些无界面的浏览器）。

Selenium 可以根据我们的指令，让浏览器自动加载页面，获取需要的数据，甚至页面截屏，或者判断网站上某些动作是否发生。

Selenium 自己不带浏览器

Selenium 库里有个叫 WebDriver 的 API。WebDriver 可以加载网站也可以查找页面元素，与页面上的元素进行交互 (发送文本、点击等)，以及执行其他动作来运行网络爬虫。

安装方式一： PyPI 网站下载安装 https://pypi.python.org/simple/selenium

安装方式二： pip install selenium

Selenium 官方参考文档：http://selenium-python.readthedocs.io/index.html

PhantomJS 简介

PhantomJS 是一个基于 Webkit 的“无界面”(headless)浏览器非 Python 库，它会把网站加载到内存并执行页面上的 JavaScript，不会展示图形界面。

把 Selenium 和 PhantomJS 结合在一起，通过 Selenium 调用 PhantomJS 来直接使用，就可以运行一个非常强大的网络爬虫了，这个爬虫可以处理 JavaScrip、Cookie、headers，以及任何我们真实用户需要做的事情。

PhantomJS 官方参考文档：http://phantomjs.org/documentation

官网下载安装 http://phantomjs.org/download.html

1、解压放到：C:\phantomjs-2.1.1-windows

2、需设置环境变量，Path 添加 C:\phantomjs-2.1.1-windows\bin

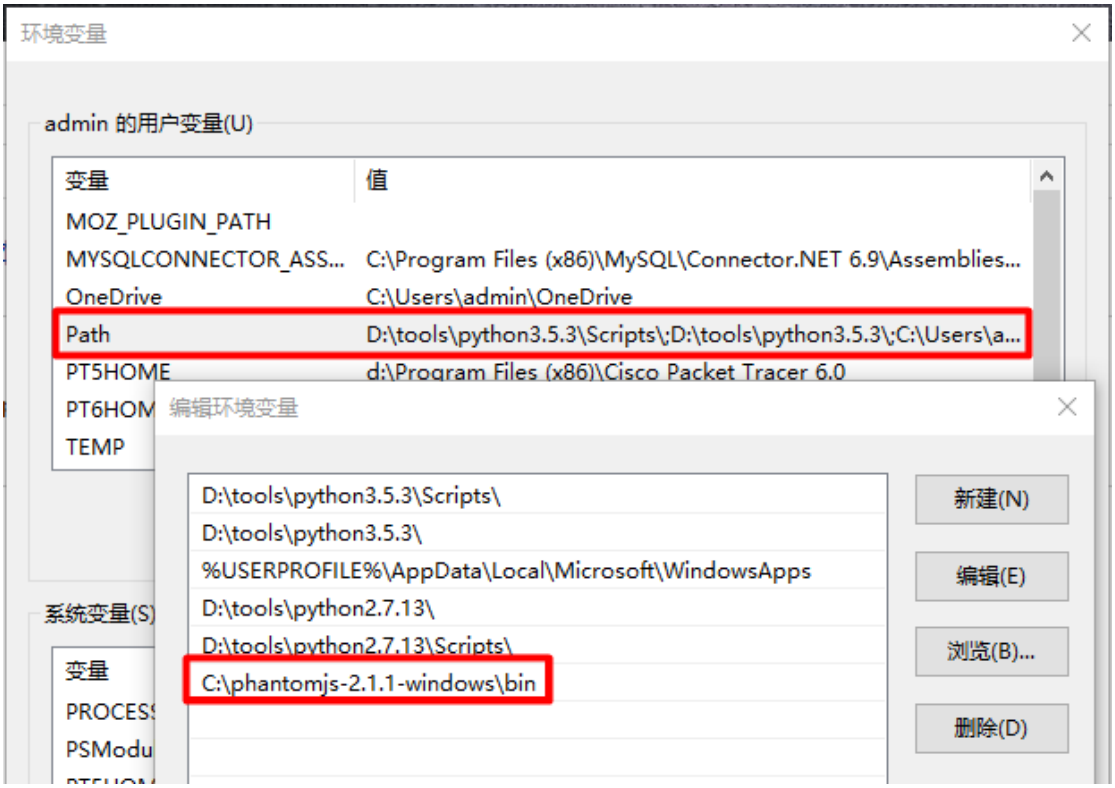

3、win+R，输入 cmd 打开控制台，输入 phantomjs -v,若输出了版本号，则证明安装成功

Chrome dirver 的安装

爬虫开发过程中使用 selenium +webdriver 打开 chrome，

chrome dirver 的安装
以 chrome 版本 65.0.3325.181
1、打开如下页面：
https://sites.google.com/a/chromium.org/chromedriver/downloads
对照下载说明，找到对应的 ChromeDriver 版本 2.38

2、打开如下网页：
http://chromedriver.storage.googleapis.com/index.html

选取 2.38 文件夹，下载对应文件

3、把 exe 文件放置到如下位置之一：

（1）chrome 的安装目录下（eg：C:\Program Files (x86)\Google\Chrome\Application）
（2）Python 的安装目录下（eg：D:\software\Python35）

4、Path 进行编辑，在变量值后面加入 chrome 或 Python 的安装目录

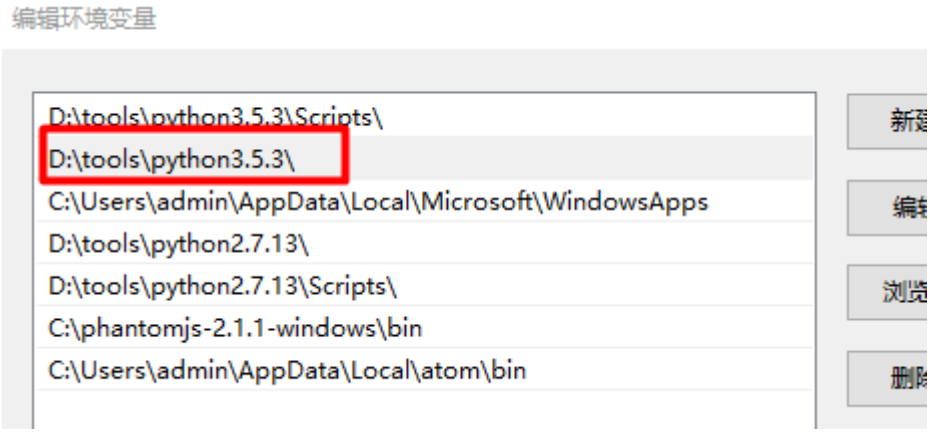

5、用 Chrome 浏览器来测试

```
from selenium import webdriver
browser = webdriver.Chrome()
browser.get('http://www.baidu.com/')
```

动态页面的请求

网页抓取

```
# 导入 webdriver
```

```
from selenium import webdriver


# 调用环境变量指定的 Chrome 浏览器创建浏览器对象
driver = webdriver. Chrome ()

# get 方法会一直等到页面被完全加载，然后才会继续程序，通常测试会在这里选择
time.sleep(2)
driver.get("http://www.baidu.com/")

# 打印网页渲染后的源代码
print(driver.page_source)

# 打印页面标题 "百度一下，你就知道"
print(driver.title)

# 获取当前 url
print(driver.current_url)

# 关闭当前页面，如果只有一个页面，会关闭浏览器
driver.close()

# 关闭浏览器
driver.quit()
```

说明：

1、要使用 selenium 首先导入 webdriver

2、生成浏览器对象 driver = webdriver.PhantomJS()

3、driver.get(url)**方法：加载指定页面，阻塞方式直到加载完成**

4、driver.find_element_by_id(elemid)**方法：获取页面指定 id 的标签**

5、driver.title**：页面标题**

6、driver.page_source**：页面源码**

7、driver.get_cookies()**：获取页面** coolies

8、driver.save_screenshot(filename)**： 保存当前页面快照**

9、driver.find_element_by_id("kw").send_keys("奇酷信息")：指定元素设置 value，通常用于 input field

10、 driver.find_element_by_id("su").click()模拟点击，通常用于按钮

11、 driver.find_element_by_id("kw").clear()：*清除输入框内容*

12、 driver.quit()：关闭浏览器

数据解析提取

定位 UI 元素（WebElements）

单个元素查找

```
find_element_by_name
find_element_by_id
find_element_by_xpath
find_element_by_link_text
find_element_by_partial_link_text
find_element_by_tag_name
find_element_by_class_name
find_element_by_css_selector
```

多个元素查找

```
find_elements_by_name
find_elements_by_id
find_elements_by_xpath
find_elements_by_link_text
find_elements_by_partial_link_text
find_elements_by_tag_name
find_elements_by_class_name
find_elements_by_css_selector
```

按 id，name，xpath，link_text，partial_link_text，tag_name，class_name，css_selector

定位 UI 元素

By ID

```
<div id="coolestWidgetEvah">...</div>
```

实现

```
element = driver.find_element_by_id("coolestWidgetEvah")
----------------------- or -------------------------
from selenium.webdriver.common.by import By
element = driver.find_element(by=By.ID, value="coolestWidgetEvah")
```

By Class Name

```
<div class="cheese"><span>Cheddar</span></div><div
class="cheese"><span>Gouda</span></div>
```

实现

```
cheeses = driver.find_elements_by_class_name("cheese")
```

By Tag Name

```
<iframe src="..."></iframe>
```

实现

```
frame = driver.find_element_by_tag_name("iframe")
```

By Name

```
<input name="cheese" type="text"/>
```

实现

```
cheese = driver.find_element_by_name("cheese")
```

By Link Text

```
<a href="http://www.google.com/search?q=cheese">cheese</a>
```

实现

```
cheese = driver.find_element_by_link_text("cheese")
```

By Partial Link Text（部分链接文本）

```
<a href="http://www.google.com/search?q=cheese">search for cheese</a>>
```

实现

```
cheese = driver.find_element_by_partial_link_text("cheese")
```

By CSS

```
<div id="food"><span class="dairy">milk</span><span class="dairy
aged">cheese</span></div>
```

实现

```
cheese = driver.find_element_by_css_selector("#food span.dairy.aged")
```

By XPath

```
<input type="text" name="example" />
<input type="text" name="other" />
```

实现

```
inputs = driver.find_elements_by_xpath("//input")
```

获取元素属性

get_attribute('class')

```
from selenium import webdriver

browser = webdriver.Chrome()
url = 'https://www.baidu.com/'
browser.get(url)
input = browser.find_element_by_id('kw')
print(input)
print(input.get_attribute('name'))
print(input.get_attribute('class'))
print(input.get_attribute('id'))
```

```
print(input.get_attribute('maxlength'))
print(input.get_attribute('autocomplete'))

browser.close()
```

获取文本值

可见元素文本：**text**

Selenium WebDriver 只会与可见元素交互，所以获取隐藏元素的文本总是会返回空字符串。

要获取隐藏元素的文本。这些内容可以使用

element.get_attribute('innerHTML')，会返回元素的内部 HTML，包含所有的 HTML 标签。

element.get_attribute('textContent'),只会得到文本内容，而不会包含 HTML 标签。是 W3C 兼容的文字内容属性，但是 IE 不支持

element.get_attribute('innerText'),只会得到文本内容，而不会包含 HTML 标签。不是 W3C DOM 的指定内容，FireFox 不支持

```
from selenium import webdriver

browser = webdriver.Chrome()
url = 'https://www.baidu.com/'
browser.get(url)
btn = browser.find_element_by_name("tj_trnews")
print(btn.text)
```

获取 ID，位置，标签名

id
location
tag_name
size

```
from selenium import webdriver
```

```
browser = webdriver.Chrome()
url = 'https://www.baidu.com/'
browser.get(url)
logo = browser.find_element_by_xpath('//div[@id="lg"]/img[@class="index-logo-src"]')
print(logo.id)
print(logo.tag_name)
print(logo.location)
print(logo.size)
```

执行 JavaScript

这是一个非常有用的方法，这里就可以直接调用 js 方法来实现一些操作，

下面的例子是通过登录知乎然后通过 js 翻到页面底部，并弹框提示

```
from selenium import webdriver
browser = webdriver.Chrome()
browser.get("http://www.zhihu.com/explore")
print(browser.page_source)
browser.execute_script('window.scrollTo(0, document.body.scrollHeight)')
browser.execute_script('alert("To Bottom")')
```

Cookies

```
get_cookies()
delete_all_cookes()
add_cookie()
```

获取页面每个 Cookies 值，用法如下

```
for cookie in driver.get_cookies():
    print "%s -> %s" % (cookie['name'], cookie['value'])
```

删除 Cookies:

```
# By name
driver.delete_cookie("CookieName")

# all
driver.delete_all_cookies()
```

范例-获取 cookie

```
from selenium import webdriver
driver = webdriver.Chrome()
# driver.get("http://member.rltxtest.xyz/login/login.html")
driver.get("http://www.youdao.com")

# 获取 cookie 信息
cookies = driver.get_cookies()
# 打印获取的 cookies 信息
print(cookies)
driver.quit()
```

范例-添加 cookie

```
from selenium import webdriver

driver = webdriver.Chrome()
# driver.get("http://member.rltxtest.xyz/login/login.html")
driver.get ("http://www.youdao.com")
# 向 cookie 中 name 和 value 中添加回话信息,
driver.add_cookie({'name': 'key-aaaaaaa','value': 'value-bbbbb'})
# 遍历 cookie 中 name 和 value 信息并打印对应的信息，并包括添加对应的信息
for cookie in driver.get_cookies():
    print("%s->%s" % (cookie['name'], cookie['value']))
driver.quit ()
```

截屏

```
driver = webdriver.Chrome()
driver.maximize_window()
driver.get("https://blog.csdn.net/Kwoky/article/details/80285201")
driver.save_screenshot("./images/app2.png")
```

超长截屏

```
driver = webdriver.PhantomJS()
driver.maximize_window()
driver.get("https://blog.csdn.net/Kwoky/article/details/80285201")
driver.save_screenshot("./images/app1.png")
```

自动化交互

鼠标动作链

在页面上模拟一些鼠标操作，比如双击、右击、拖拽甚至按住不动等，可以通过导入 ActionChains 类实现

ActionChains 执行原理

当调用ActionChains的方法时,不会立即执行,而是会将所有的操作按顺序存放在一个队列里，当你调用 perform()方法时，队列中的时间会依次执行。

有两种写法本质是一样的，ActionChains 都会按照顺序执行所有的操作。

链式写法

```
menu = driver.find_element_by_css_selector(".nav")
hidden_submenu =        driver.find_element_by_css_selector(".nav #submenu1")
ActionChains(driver).move_to_element(menu).click(hidden_submenu).perform()
```

分步写法

```
menu = driver.find_element_by_css_selector(".nav")
hidden_submenu = driver.find_element_by_css_selector(".nav #submenu1")

actions = ActionChains(driver)
actions.move_to_element(menu)
actions.click(hidden_submenu)
actions.perform()
```

ActionChains 方法列表

click(*on_element=None*) ——单击鼠标左键
click_and_hold(*on_element=None*) ——点击鼠标左键，不松开
context_click(*on_element=None*) ——点击鼠标右键
double_click(*on_element=None*) ——双击鼠标左键
drag_and_drop(*source, target*) ——拖拽到某个元素然后松开
drag_and_drop_by_offset(*source, xoffset, yoffset*) ——拖拽到某个坐标然后松开
key_down(*value, element=None*) ——按下某个键盘上的键
key_up(*value, element=None*) ——松开某个键
move_by_offset(*xoffset, yoffset*) ——鼠标从当前位置移动到某个坐标
move_to_element(*to_element*) ——鼠标移动到某个元素
move_to_element_with_offset(*to_element, xoffset, yoffset*) ——移动到距某个元素（左上角坐标）多少距离的位置
perform() ——执行链中的所有动作
release(*on_element=None*) ——在某个元素位置松开鼠标左键
send_keys(**keys_to_send*) ——发送某个键到当前焦点的元素
send_keys_to_element(*element, *keys_to_send*) ——发送某个键到指定元素

代码示例

1.模拟点击

```
from selenium import webdriver
from selenium.webdriver.common.action_chains import ActionChains
from time import sleep

driver = webdriver.Chrome()
driver.implicitly_wait(10)
driver.maximize_window()
driver.get('http://sahitest.com/demo/clicks.htm')

click_btn = driver.find_element_by_xpath('//input[@value="click me"]')  # 单击按钮
doubleclick_btn = driver.find_element_by_xpath('//input[@value="dbl click me"]')  # 双击按钮
rightclick_btn = driver.find_element_by_xpath('//input[@value="right click me"]')  # 右键单击按钮

ActionChains(driver).click(click_btn).double_click(doubleclick_btn).context_click(rightclick_btn).perfor
m()  # 链式用法

print(driver.find_element_by_name('t2').get_attribute('value'))
```

```
sleep(2)
driver.quit()
```

结果：

```
[CLICK][DOUBLE_CLICK][RIGHT_CLICK]
```

2.鼠标移动

```
from selenium import webdriver
from selenium.webdriver.common.action_chains import ActionChains
from time import sleep

driver = webdriver.Chrome()
driver.implicitly_wait(10)
driver.maximize_window()
driver.get('http://sahitest.com/demo/mouseover.htm')

write = driver.find_element_by_xpath('//input[@value="Write on hover"]')  # 鼠标移动到此元素，在下面的 input 框中会显示“Mouse moved”
blank = driver.find_element_by_xpath('//input[@value="Blank on hover"]')  # 鼠标移动到此元素，会清空下面 input 框中的内容

result = driver.find_element_by_name('t1')

action = ActionChains(driver)
action.move_to_element(write).perform()  # 移动到 write，显示“Mouse moved”
print(result.get_attribute('value'))

# action.move_to_element(blank).perform()
action.move_by_offset(10, 50).perform()  # 移动到距离当前位置(10,50)的点，与上句效果相同，移动到 blank 上，清空
print(result.get_attribute('value'))

action.move_to_element_with_offset(blank, 10, -40).perform()  # 移动到距离 blank 元素(10,-40)的点，可移动到 write 上
print(result.get_attribute('value'))

sleep(2)
driver.quit()
```

结果

```
Mouse moved



Mouse moved
```

3.拖拽

```
from selenium import webdriver
from selenium.webdriver.common.action_chains import ActionChains
from time import sleep

driver = webdriver.Chrome()
driver.implicitly_wait(10)
driver.maximize_window()
driver.get('http://sahitest.com/demo/dragDropMooTools.htm')

dragger = driver.find_element_by_id('dragger')  # 被拖拽元素
item1 = driver.find_element_by_xpath('//div[text()="Item 1"]')  # 目标元素 1
item2 = driver.find_element_by_xpath('//div[text()="Item 2"]')  # 目标 2
item3 = driver.find_element_by_xpath('//div[text()="Item 3"]')  # 目标 3
item4 = driver.find_element_by_xpath('//div[text()="Item 4"]')  # 目标 4

action = ActionChains(driver)
action.drag_and_drop(dragger, item1).perform()  # 1.移动 dragger 到目标 1
sleep(2)
action.click_and_hold(dragger).release(item2).perform()  # 2.效果与上句相同，也能起到移动效果
sleep(2)
action.click_and_hold(dragger).move_to_element(item3).release().perform()  # 3.效果与上两句相同，也能起到移动的效果
sleep(2)
# action.drag_and_drop_by_offset(dragger, 400, 150).perform()  # 4.移动到指定坐标
action.click_and_hold(dragger).move_by_offset(400, 150).release().perform()  # 5.与上一句相同，移动到指定坐标
sleep(2)
driver.quit()
```

一般用坐标定位很少，用上例中的方法 1 足够了，如果看源码，会发现方法 2 其实就是方法 1 中的 drag_and_drop()的实现。**注意：拖拽使用时注意加等待时间，有时会因为速度太快而失**

败。

4.按键

模拟按键有多种方法，能用 win32api 来实现，能用 SendKeys 来实现，也可以用 selenium 的 WebElement 对象的 send_keys()方法来实现，这里 ActionChains 类也提供了几个模拟按键的方法。

```
from selenium import webdriver
from selenium.webdriver.common.action_chains import ActionChains
# 要想调用键盘按键操作需要引入 keys 包
from selenium.webdriver.common.keys import Keys
from time import sleep


driver = webdriver.Chrome()
driver.implicitly_wait(10)
driver.maximize_window()
driver.get('http://sahitest.com/demo/keypress.htm')

key_up_radio = driver.find_element_by_id('r1')   # 监测按键升起
key_down_radio = driver.find_element_by_id('r2')   # 监测按键按下
key_press_radio = driver.find_element_by_id('r3')   # 监测按键按下升起

enter = driver.find_elements_by_xpath('//form[@name="f1"]/input')[1]   # 输入框
result = driver.find_elements_by_xpath('//form[@name="f1"]/input')[0]   # 监测结果

# 监测 key_down
key_down_radio.click()
ActionChains(driver).key_down(Keys.CONTROL, enter).key_up(Keys.CONTROL).perform()
print(result.get_attribute('value'))

# 监测 key_up
key_up_radio.click()
enter.click()
ActionChains(driver).key_down(Keys.SHIFT).key_up(Keys.SHIFT).perform()
print(result.get_attribute('value'))

# 监测 key_press
```

```
key_press_radio.click()
enter.click()
ActionChains(driver).send_keys('a').perform()
print(result.get_attribute('value'))
driver.quit()
```

结果：

```
key downed charCode=[0] keyCode=[17] CTRL
key upped charCode=[0] keyCode=[16] NONE
key pressed charCode=[97] keyCode=[0] NONE
```

案例：百度自动化搜索

```
# 导入 webdriver
from selenium import webdriver


# 调用环境变量指定的 Chrome 浏览器创建浏览器对象
driver = webdriver. Chrome ()

# get 方法会一直等到页面被完全加载，然后才会继续程序，通常测试会在这里选择
time.sleep(2)
driver.get("http://www.baidu.com/")

# id="kw"是百度搜索输入框，输入字符串"长城"
driver.find_element_by_id("kw").send_keys("奇酷信息")

# id="su"是百度搜索按钮，click() 是模拟点击
driver.find_element_by_id("su").click()

# 获取新的页面快照
driver.save_screenshot("奇酷信息.png")

# 清除输入框内容
driver.find_element_by_id("kw").clear()
print('============')


# 关闭当前页面，如果只有一个页面，会关闭浏览器
driver.close()
```

```
# 关闭浏览器
driver.quit()
```

html 元素操作

窗口最大化

```
driver.maximize_window()
```

下拉框的处理

有时候我们会碰到<select> </select>标签的下拉框。直接点击下拉框中的选项不一定可行。

Selenium 专门提供了 Select 类来处理下拉框完成这些事情

- Select 提供了三种选择方法:

```
select_by_index(index) ——通过选项的顺序，第一个为 0
select_by_value(value) ——通过 value 属性
select_by_visible_text(text) ——通过选项可见文本
```

- 全部取消选择:

```
select.deselect_all()
```

- Select 提供了相应属性，选择了选项之后，查看所选项

```
options ——提供所有的选项的列表，其中都是选项的 WebElement 元素
all_selected_options ——提供所有被选中的选项的列表，其中也均为选项的 WebElement 元素
first_selected_option ——提供第一个被选中的选项，也是下拉框的默认值
```

范例

```
from selenium import webdriver
from selenium.webdriver.support.ui import Select

driver = webdriver.Chrome()
driver.get('http://sahitest.com/demo/selectTest.htm')

s1 = Select(driver.find_element_by_id('s1Id'))  # 实例化 Select
```

```
s1.select_by_index(1)  # 选择第二项选项：o1
print(s1.first_selected_option.text)
s1.select_by_value("o2")  # 选择 value="o2"的项
print(s1.first_selected_option.text)
s1.select_by_visible_text("o3")  # 选择 text="o3"的值，即在下拉时我们可以看到的文本
print(s1.first_selected_option.text)
driver.quit()
```

弹窗处理

当你触发了某个事件之后，页面出现了弹窗提示，处理这个提示或者获取提示信息方法如下：

```
alert = driver.switch_to_alert()
```

用 switch_to_alert 先定位到弹窗，然后使用一系列方法来操作：

accept - 点击【确认】按钮

dismiss - 点击【取消】按钮（如有按钮）

send_keys - 输入内容（如有输入框）

```
from selenium import webdriver
import time

driver = webdriver.Chrome()
driver.get("http://sahitest.com/demo/alertTest.htm")
driver.find_element_by_name("b1").click()
time.sleep(1)
al = driver.switch_to_alert()
time.sleep(1)
al.accept()
```

switch_to_alert()是旧写法，新写法应该是 switch_to.alert()，但是会报错，猜测是版本问题。

页面切换

一个浏览器肯定会有很多窗口，切换窗口的方法如下：

```
driver.switch_to.window("this is window name")
```

也可以使用 window_handles 方法来获取每个窗口的操作对象。例如：

```
for handle in driver.window_handles:
    driver.switch_to_window(handle)
```

页面前进和后退

操作页面的前进和后退功能：

```
driver.forward()     #前进
driver.back()        # 后退
```

```
from selenium import webdriver
import time

driver = webdriver.Chrome()
driver.implicitly_wait(3) # seconds
first_url = 'http://www.baidu.com/'
driver.get(first_url)
print(driver.title)   # 第一个页面
driver.find_element_by_link_text("新闻").click()
driver.switch_to_window(driver.window_handles[0])
print(driver.title)   # 第一个页面
#browser.switch_to_window(browser.window_handles[1])
#browser.title   # 最后一个页面
time.sleep(2)
driver.back()   # 从百度新闻后退到百度首页
print(driver.title)   # 第一个页面
time.sleep(2)
driver.forward() # 百度首页前进到百度新闻
print(driver.title)   # 第一个页面
time.sleep(2)
driver.quit()
```

运行结果

```
百度一下，你就知道
百度新闻——全球最大的中文新闻平台
百度一下，你就知道
百度新闻——全球最大的中文新闻平台
```

选项卡管理

通过执行 js 命令实现新开选项卡 window.open()

不同的选项卡是存在列表里 browser.window_handles

通过 browser.window_handles[0]就可以操作第一个选项卡

```
import time
from selenium import webdriver

browser = webdriver.Chrome()
browser.get('https://www.baidu.com')
browser.execute_script('window.open()')
print(browser.window_handles)
browser.switch_to_window(browser.window_handles[1])
browser.get('https://www.taobao.com')
time.sleep(1)
browser.switch_to_window(browser.window_handles[0])
browser.get('https://python.org')
```

iframe 定位

切换到 iframe

```
driver.switch_to.frame(0)  # 用 frame 的 index 来定位，第一个是 0
driver.switch_to.frame("frame1")  # 用 id 来定位
driver.switch_to.frame("myframe")  # 用 name 来定位，有 name，并且唯一
driver.switch_to.frame(driver.find_element_by_tag_name("iframe"))  # 用 WebElement 对象来定位
```

从 frame 中切回主文档

```
driver.switch_to.default_content()
```

嵌套 frame 返回父 frame

```
driver.switch_to.parent_frame()
```

范例：

```
from selenium import    webdriver
import time

driver = webdriver.Chrome()
driver.maximize_window()
```

```
# get 方法会一直等到页面被完全加载，然后才会继续程序，通常测试会在这里选择 time.sleep(2)
driver.get("http://sahitest.com/demo/iframesTest.htm")
time.sleep(2)
print(driver.current_url)
print(driver.page_source)
frames = driver.find_elements_by_tag_name("iframe")
driver.switch_to_frame(frames[0])
print('================================================')
print(driver.page_source)
```

页面刷新

```
driver.navigate().refresh()
driver.get(driver.getCurrentUrl())
driver.navigate().to(driver.getCurrentUrl())
driver.executeScript("history.go(0)")
```

页面等待

注意：这是非常重要的一部分!!

现在的网页越来越多采用了 Ajax 技术，这样程序便不能确定何时某个元素完全加载出来了。如果实际页面等待时间过长导致某个 dom 元素还没出来，但是你的代码直接使用了这个 WebElement，那么就会抛出 NullPointer 的异常。

为了避免这种元素定位困难而且会提高产生 ElementNotVisibleException 的概率。所以 Selenium 提供了两种等待方式，一种是隐式等待，一种是显式等待。

隐式等待是等待特定的时间，显式等待是指定某一条件直到这个条件成立时继续执行。

显式等待

显式等待指定某个条件，然后设置最长等待时间。如果在这个时间还没有找到元素，那么便会抛

出异常了。

```
from selenium import webdriver
from selenium.webdriver.common.by import By
# WebDriverWait 库，负责循环等待
from selenium.webdriver.support.ui import WebDriverWait
# expected_conditions 类，负责条件触发
from selenium.webdriver.support import expected_conditions as EC

driver = webdriver.Chrome()
driver.get("http://www.xxxxx.com/loading")
try:
    # 页面一直循环，直到 id="myDynamicElement" 出现
    element = WebDriverWait(driver, 10).until(
        EC.presence_of_element_located((By.ID, "myDynamicElement"))
    )
finally:
    driver.quit()
```

如果不写参数，程序默认会 0.5s 调用一次来查看元素是否已经生成，如果本来元素就是存在的，那么会立即返回。

下面是一些内置的等待条件，你可以直接调用这些条件，而不用自己写某些等待条件了。

```
title_is 标题是某内容
title_contains 标题包含某内容
presence_of_element_located 元素加载出，传入定位元组，如(By.ID, 'p')
visibility_of_element_located 元素可见，传入定位元组
visibility_of 可见，传入元素对象
presence_of_all_elements_located 所有元素加载出
text_to_be_present_in_element 某个元素文本包含某文字
text_to_be_present_in_element_value 某个元素值包含某文字
frame_to_be_available_and_switch_to_it frame 加载并切换
invisibility_of_element_located 元素不可见
element_to_be_clickable 元素可点击
staleness_of 判断一个元素是否仍在 DOM，可判断页面是否已经刷新
element_to_be_selected 元素可选择，传元素对象
element_located_to_be_selected 元素可选择，传入定位元组
element_selection_state_to_be 传入元素对象以及状态，相等返回 True，否则返回 False
element_located_selection_state_to_be 传入定位元组以及状态，相等返回 True，否则返回 False
alert_is_present 是否出现 Alert
```

隐式等待

隐式等待比较简单，就是简单地设置一个等待时间，单位为秒。

```
from selenium import webdriver

driver = webdriver.Chrome()
driver.implicitly_wait(10) # seconds
driver.get("http://www.xxxxx.com/loading")
myDynamicElement = driver.find_element_by_id("myDynamicElement")
```

当然如果不设置，默认等待时间为 0。

浏览器配置选项

配置 chrome 浏览器的选项

在使用 selenium 浏览器渲染技术，爬取网站信息时，默认情况下就是一个普通的纯净的 chrome 浏览器，而我们平时在使用浏览器时，经常就添加一些插件，扩展，代理之类的应用。相对应的，当我们用 chrome 浏览器爬取网站时，可能需要对这个 chrome 做一些特殊的配置，以满足爬虫的行为。

常用的行为有：

禁止图片和视频的加载：提升网页加载速度。

添加代理：用于翻墙访问某些页面，或者应对 IP 访问频率限制的反爬技术。

使用移动头：访问移动端的站点，一般这种站点的反爬技术比较薄弱。

添加扩展：像正常使用浏览器一样的功能。

设置编码：应对中文站，防止乱码。

阻止 JavaScript 执行。

chromeOptions 对象创建

chromeOptions 是一个配置 chrome 启动时属性的类。

options = webdriver.ChromeOptions()

禁止图片加载

prefs = {"profile.managed_default_content_settings.images": 2}
options.add_experimental_option("prefs", prefs)

无界面浏览器

不提供可视化页面.

options.add_argument('--headless')

或者
opt.set_headless() # 把 chrome 设置成无头模式，不论 windows 还是 linux 都可以，自动适配对应参数

添加代理 ip

chromeOptions.add_argument("--proxy-server=http://202.20.16.82:10152")

添加 UA

options.add_argument('user-agent="MQQBrowser/26 Mozilla/5.0 (Linux; U; Android 2.3.7; zh-cn; MB200 Build/GRJ22; CyanogenMod-7) AppleWebKit/533.1 (KHTML, like Gecko) Version/4.0 Mobile Safari/533.1"')

禁用浏览器弹窗

```
prefs = {
    'profile.default_content_setting_values' :  {
        'notifications' : 2
     }
}
options.add_experimental_option('prefs',prefs)
```

禁用 JavaScript

```
option.add_argument("--disable-javascript")
```

以最高权限运行

```
options.add_argument('--no-sandbox')
```

创建定制选项的浏览器对象

```
driver = webdriver.Chrome(chrome_options= options)
```

范例

无界面浏览器

```
opt = webdriver.ChromeOptions()  # 创建 chrome 参数对象
opt.set_headless()  # 把 chrome 设置成无头模式，不论 windows 还是 linux 都可以，自动适配对应参数
driver = webdriver.Chrome(options=opt)  # 不制定 options 选项则是普通有头浏览器
```

代理 ip 的使用

```
ip = '123.157.67.30:34942'
```

```
chome_options = webdriver.ChromeOptions()
chome_options.add_argument(('--proxy-server=http://' + ip))

url = 'http://www.gsxt.gov.cn/index.html'
driver = webdriver.Chrome(chrome_options=chome_options)
driver.get(url)
time.sleep(2)
print(driver.page_source)
driver.close()
```